Поиск мошеннических транзакций

Задача, датасет и бейзлайны: табличные модели и GNN

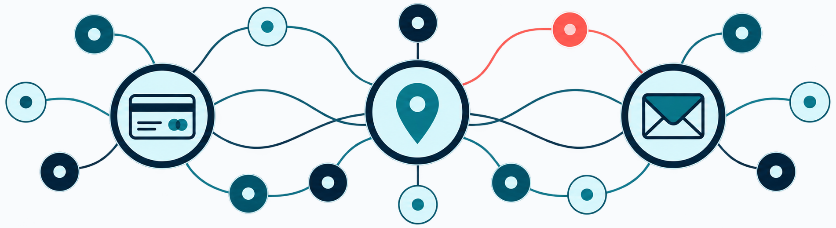
ЗАДАЧА

Оценить вероятность мошенничества (isFraud = 1) по данным транзакции. Сравнить табличные модели с GNN, которые используют связи по общим реквизитам.

ДАТАСЕТ IEEE-CIS

590 540 транзакций; 3,5% — мошеннические
4 804 признака после обработки; разделение 60/20/20

Общие реквизиты связывают транзакции в граф



БЕЙЗЛАЙНЫ: ТАБЛИЧНЫЕ И GNN

Наш тест. SOTA ниже: другие разбиения

Модель	ROC-AUC	PR-AUC	Обучение, с
XGBoost	0,8612	0,4600	426,2
LightGBM	0,8375	**0,4610**	46,5
CatBoost	**0,8689**	0,4495	102,7
GCN (homo)	0,6621	0,0831	544,8
GraphSAGE (homo)	0,8097	0,2215	551,5
GraphConv (hetero)	0,8342	**0,4139**	767,2

SOTA бустингов: ROC-AUC 0,9459 (XGB + LGBM + CatBoost)

SOTA графов: ROC-AUC 0,9487 (TransFraudGNN, 2026)

Вывод: LightGBM лидирует по PR-AUC (0,461); лучшая из показанных GNN — hetero GraphConv (0,414).